

# Teoría de Decisión Bayesiana



**BAYESIAN DECISION THEORY**

**VARIABLE CONTINUA**

# Reglas de Decisión

2

- Observando la cinta de traslado es difícil predecir que pez va pasar primero
  - La secuencia de peces parece ser aleatoria.
- Terminología de teoría de decisión:
  - la naturaleza presenta dos estados
  - Cada estado es impredecible, por lo cual debe ser descrito en forma probabilística
- Estado verdadero  $\omega$  es una variable aleatoria
  - Dos estados verdaderos posibles:

$$\omega_1 = \text{Salmon} , \omega_2 = \text{Mero}$$

# Reglas de Decisión

3

- Las probabilidades de los estados reflejan el conocimiento previo sobre las características de los peces.
- Probabilidades a priori
  - Pesca del Salmon  $P(\omega_1)$
  - Pesca del Mero  $P(\omega_2)$
$$P(\omega_1) + P(\omega_2) = 1$$
- Por ejemplo si se suelen obtener tantos salmones como meros en la región, se puede decir que igualmente probable pescar un salmón que un mero si uno tira una línea.
  - $P(\omega_1) = P(\omega_2)$  equiprobables

# Regla de Decisión solo con información a priori

4

- Decide  $\omega_1$  si  $P(\omega_1) > P(\omega_2)$ 
  - en otro caso decide  $\omega_2$
- Tiene sentido si solo juzgo el próximo pez.
- Error? Me equivoco con toda la clase menos probable!!!
- Sin embargo si no sé otra cosa, es la regla con menor error

# Regla de Decisión con variable X

5

Por eso es que necesitamos diseñar y calcular caracterizaciones discriminatorias de los estados

- X es la luminosidad de las escamas del pez
- $p_X(x | \omega_1)$  y  $p_X(x | \omega_2)$  describen la diferencia en luminosidad de las escamas entre poblaciones de Mero y Salmón
- $P(\omega_1)$  y  $P(\omega_2)$  son las probabilidades a priori de la pesca
- Evidencia es la densidad de la variable X

$$p_X(x) = \sum_{j=1}^{j=2} p(x | \omega_j) P(\omega_j)$$


# Regla de Decisión con variable X

6

## Información condicional a la clase concentrada en una variable aleatoria X

- X es una variable aleatoria
- $p(x | \omega_1)$  y  $p(x | \omega_2)$  probabilidades condicionadas a los estados
- $P(\omega_1)$  y  $P(\omega_2)$  son las probabilidades a priori
- Evidencia es la densidad de la variable X

$$p_X(x) = \sum_{j=1}^{j=2} p(x | \omega_j) P(\omega_j)$$



**FIGURE 2.1.** Hypothetical class-conditional probability density functions show the probability density of measuring a particular feature value  $x$  given the pattern is in category  $\omega_i$ . If  $x$  represents the lightness of a fish, the two curves might describe the difference in lightness of populations of two types of fish. Density functions are normalized, and thus the area under each curve is 1.0. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

# Regla de Decisión con variable X

8

Observamos ahora una característica X y tiene el valor x. Como influye esto en la determinación del estado del pez?

- X es una variable aleatoria que toma un valor x
- $p(x | \omega_1)$  y  $p(x | \omega_2)$  probabilidades condicionadas a los estados
- $P(\omega_1)$  y  $P(\omega_2)$  son las probabilidades a priori
- La probabilidad conjunta de x y  $\omega$  es

$$p(\omega_j, x) = P(\omega_j | x) \cdot p(x) = p(x | \omega_j) \cdot P(\omega_j)$$



# Regla de Decisión con variable X


9

Probabilidad del estado  $\omega$  dado que se observa el valor  $x$  es llamada probabilidad a posteriori

$$P(\omega_j | x) = \frac{p(x | \omega_j)P(\omega_j)}{p(x)}$$

- Posterior = (Verosimilitud condicional x Prior) / Evidencia
- La evidencia es la densidad de la variable X

$$p_X(x) = \sum_{j=1}^{j=2} p(x | \omega_j)P(\omega_j)$$



**FIGURE 2.2.** Posterior probabilities for the particular priors  $P(\omega_1) = 2/3$  and  $P(\omega_2) = 1/3$  for the class-conditional probability densities shown in Fig. 2.1. Thus in this case, given that a pattern is measured to have feature value  $x = 14$ , the probability it is in category  $\omega_2$  is roughly 0.08, and that it is in  $\omega_1$  is 0.92. At every  $x$ , the posteriors sum to 1.0. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

# Decisión dadas las probabilidades a posteriori

11

$x$  es una observación:

si  $P(\omega_1 | x) > P(\omega_2 | x)$   Decido estado natural =  $\omega_1$   
si  $P(\omega_1 | x) < P(\omega_2 | x)$   Decido estado natural =  $\omega_2$

## Error

- Verdadero =  $\omega_1$  Si me equivoco, decido por  $\omega_2$  es porque  $P(\omega_1 | x) < P(\omega_2 | x)$ . Por lo cual  $P(\text{error} | x) = P(\omega_1 | x)$
- Verdadero =  $\omega_2$  Si me equivoco, decido por  $\omega_1$  es porque  $P(\omega_1 | x) > P(\omega_2 | x)$ . Por lo cual  $P(\text{error} | x) = P(\omega_2 | x)$
- En ambos casos, la probabilidad a posteriori es la mas chica

$$P(\text{error} | x) = \min [P(\omega_1 | x), P(\omega_2 | x)]$$

# Regla de Bayes

12

- La regla de Bayes es la regla que produce el mínimo error promedio

*Produce la regla basada en las probabilidades a posteriori el mínimo error promedio??*

*Es la regla basada en las probabilidades a posteriori la regla de Bayes??*

# Error promedio

13

- La probabilidad de error promedio es

$$P(error) = \int_{-\infty}^{\infty} P(error, x) dx = \int_{-\infty}^{\infty} P(error | x) p(x) dx$$

- Y si  $P(error | x)$  es lo mas chico posible, la integral es la mas chica posible.

# Error promedio

14

- Ahora, para cualquier regla, en cuanto observamos un  $x$  particular,  $P(\text{error} \mid x)$  es :

- $P(\text{error} \mid x) = P(\omega_1 \mid x)$  si decidimos por  $\omega_2$  si era  $\omega_1$
- $P(\text{error} \mid x) = P(\omega_2 \mid x)$  si decidimos por  $\omega_1$  si era  $\omega_2$

- Por lo cual la regla cuyo error es

$$P(\text{error} \mid x) = \min [P(\omega_1 \mid x), P(\omega_2 \mid x)]$$

Es la regla con mínimo error promedio

# Regla de Bayes

15

- En este contexto (conocemos probabilidades a priori y a posteriori)

*La regla de Bayes es la regla basada en las probabilidades a posteriori*

# Regla de Bayes

16

- La regla de Bayes

si  $P(\omega_1 | x) > P(\omega_2 | x)$  Decido estado natural =  $\omega_1$   
si  $P(\omega_1 | x) < P(\omega_2 | x)$  Decido estado natural =  $\omega_2$

- puede expresarse como

Decidir  $\omega_1$  si  $p(x | \omega_1) P(\omega_1) > p(x | \omega_2) P(\omega_2)$ ;  
en otro caso decidir  $\omega_2$



# Generalización de las ideas precedentes

17

- Usar más de una característica
- Usar más de dos estados verdaderos
- Permitir acciones y no solo decidir el estado verdadero
- Introducir una función de pérdida que es mas general que la probabilidad de error

# Generalizaciones

18

- Permitir otras acciones además que la clasificación
  - Permitir la posibilidad de rechazo:
  - Esto es, no tomar una decisión en casos cercanos o en malos casos!
- Introducir una función de pérdida :
  - La función de perdida dice cuanto cuesta cada acción que se toma

# Generalizaciones

19

- Sea  $\{\omega_1, \omega_2, \dots, \omega_c\}$  el conjunto de  $c$  estados verdaderos (o “categorías”)
- Sea  $\{\alpha_1, \alpha_2, \dots, \alpha_a\}$  el conjunto de posibles acciones
- Sea  $\lambda(\alpha_i | \omega_j)$  la pérdida incurrida por tomar la acción  $\alpha_i$  cuando el estado verdadero es  $\omega_j$
- $X$  es un vector aleatorio y  $p(x | \omega_j)$  es la probabilidad condicional de  $X$  cuando  $\omega_j$  es verdadero

# Posterior, verosimilitud, evidencia

20

- Posterior = (Verosimilitud x Prior) / Evidencia

$$P(\omega_j | x) = \frac{p(x | \omega_j)P(\omega_j)}{P(x)}$$

- Evidencia

$$P(x) = \sum_{j=1}^c p(x | \omega_j)P(\omega_j)$$

# Riesgo condicional

21

- Sea  $\lambda(\alpha_i | \omega_j)$  la pérdida incurrida por tomar la acción  $\alpha_i$  cuando el estado verdadero es  $\omega_j$ ,
- La pérdida esperada dada la observación  $x$  es

$$R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | x) \quad i = 1, \dots, a$$

- Y se llama *Riesgo condicional*

# Regla de Bayes

22

Se busca una regla  $\alpha(x)$  que minimice el Riesgo

$$R = \int R(\alpha(x) | x) p(x) dx$$

Minimizar  $R \iff$  Minimizar  $R(\alpha_i | x)$  para  $i = 1, \dots, a$

Por lo cual se busca un conjunto de acciones  $\alpha_i$  para las cuales  $R(\alpha_i | x)$  es mínimo

# Riesgo de Bayes es el error de la Regla de Bayes

23

- Ese conjunto de acciones  $\alpha^*(x)$  es la *regla de decisión de Bayes*
- Para ese conjunto de acciones  $\alpha^*(x)$ , el valor de la integral

$$R^* = \int R(\alpha^*(x) | x) p(x) dx$$

se llama riesgo de Bayes y es el mejor desempeño posible!

# Clasificación de dos categorías

24

- Reglas de decisión

$\alpha_1$  : decide por  $\omega_1$

$\alpha_2$  : decide por  $\omega_2$

✦ Pérdida incurrida al decidir por  $\omega_i$  cuando el verdadero estado natural es  $\omega_j$  es

$$\lambda_{ij} = \lambda(\alpha_i \mid \omega_j)$$

- Riesgo condicional:

$$R(\alpha_1 \mid x) = \lambda_{11}P(\omega_1 \mid x) + \lambda_{12}P(\omega_2 \mid x)$$

$$R(\alpha_2 \mid x) = \lambda_{21}P(\omega_1 \mid x) + \lambda_{22}P(\omega_2 \mid x)$$



# Regla de Bayes

25

La regla de Bayes minimiza el riesgo condicional

La regla es la siguiente :

$$\text{si } R(\alpha_1 | x) < R(\alpha_2 | x)$$

se toma la acción  $\alpha_1$ : “decide por  $\omega_1$ ”

Si no se toma la acción  $\alpha_2$ : “decide por  $\omega_2$ ”

**Pruebe que minimiza el riesgo!!!**

# Regla de Bayes

26

Reemplazando....

“ Decidir por  $\omega_1$  si:

$$(\lambda_{21} - \lambda_{11})p(x | \omega_1)P(\omega_1) > (\lambda_{12} - \lambda_{22})p(x | \omega_2).P(\omega_2)$$

decidir por  $\omega_2$  en otro caso”

# Regla de Bayes

27

Si además suponemos que  $\lambda_{21} > \lambda_{11}$

- *Si ocurre que*

$$\frac{p(x | \omega_1)}{p(x | \omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \cdot \frac{P(\omega_2)}{P(\omega_1)} = T^*$$

*tome acción  $\alpha_1$  (decida por  $\omega_1$ )*

- *En otro caso tome acción  $\alpha_2$  (decida por  $\omega_2$ )*

# Propiedad de decisión optima

28

“Si el cociente de verosimilitudes excede el valor de un umbral  $T^*$  que es independiente del patrón ingresado  $x$ , se pueden tomar decisiones optimas”

# Densidad Normal

29

- Densidad analíticamente manejable
- Densidad continua
- Muchos procesos son asintóticamente Gaussianos
- Caracteres escritos a mano, sonidos del habla se modelan como prototipos corruptos por un proceso aleatorio


$$P(x) = \frac{1}{\sqrt{2\pi} \sigma} \exp\left[-\frac{1}{2}\left(\frac{x - \mu}{\sigma}\right)^2\right],$$

$\mu$  = esperanza de  $X$

$\sigma^2$  = varianza

# Densidad Normal

30



**FIGURE 2.7.** A univariate normal distribution has roughly 95% of its area in the range  $|x - \mu| \leq 2\sigma$ , as shown. The peak of the distribution has value  $p(\mu) = 1/\sqrt{2\pi}\sigma$ . From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

# Ejemplo

31

Seleccionar la decisión óptima cuando :

$$\mathcal{X} = \{\omega_1, \omega_2\}$$

$$p(x | \omega_1) \longrightarrow N(2, 0.5) \text{ (distribución Normal)}$$

$$p(x | \omega_2) \longrightarrow N(1.5, 0.2)$$

$$P(\omega_1) = 2/3$$

$$P(\omega_2) = 1/3$$

$$\lambda = \begin{bmatrix} 1 & 2 \\ 3 & 0.4 \end{bmatrix}$$

La condición que deben cumplir los  $\lambda$  son  $\lambda_{21} > \lambda_{11}$ ,  $\lambda_{12} > \lambda_{22}$

# Ejemplo

32

$$\frac{p(x | \omega_1)}{p(x | \omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \cdot \frac{P(\omega_2)}{P(\omega_1)}$$

$$\frac{\frac{1}{\sqrt{2\pi} \cdot 0.5} \exp\left[-\frac{1}{2} \left(\frac{x-2}{0.5}\right)^2\right]}{\frac{1}{\sqrt{2\pi} \cdot 0.2} \exp\left[-\frac{1}{2} \left(\frac{x-1.5}{0.2}\right)^2\right]} > \frac{2-0.4}{3-1} \cdot \frac{2/3}{1/3}$$



# Ejemplo

33

- *Si ocurre que*

$$2 * \ln(0.2 / 0.5) - \left( \frac{x - 2}{0.5} \right)^2 + \left( \frac{x - 1.5}{0.2} \right)^2 > 1.6$$

*tome acción  $\alpha_1$  (decida por  $\omega_1$ )*

- *En otro caso tome acción  $\alpha_2$  (decida por  $\omega_2$ )*